

A Transformada Wavelet no Processamento e Compressão de Imagens

Vicente I. Becerra Sablón

Doutor e Mestre em engenharia Elétrica pela UNICAMP

Consultor da Tcp –Telecom e Professor do Centro Universitário UNISAL –Campinas

Tel: (019) 32421698

Fax: (19) 3788 4995

e-mail: vsablon@sj.unisal.br

Endereço: Rua Alberto Jackson, 573. Jd. Chapadão. 13066430. Campinas SP.

Luiz Rômulo Mendez

Mestre em engenharia Elétrica pela UNICAMP

Consultor da Tcp –Telecom e Professor do Centro Universitário UNISAL –Campinas

Tel: (019) 32421698

Fax: (19) 3788 4995

e-mail: luis.romulo@tcptelecom.com.br

Yuzo Iano

Doutor e Mestre em engenharia Elétrica pela UNICAMP

Professor do Departamento de Comunicações da Faculdade Engenharia Elétrica e

Computação da UNICAMP e Responsável pelo Laboratório de Comunicações Visuais do

DECOM/FEEC/UNICAMP

Tel: (19) 3 788 3809

Fax: (19) 3 289 1395

e-mail: yuzo@decom.fee.unicamp.br;

Resumo

Este trabalho apresenta uma análise sobre as potencialidades de aplicação da transformada *wavelet* na compressão e processamento de imagens. Realiza-se um estudo da teoria *wavelet*, bem como um estudo comparativo entre os algoritmos *wavelets* considerados como estado da arte em compressão de imagens. Analisa-se os principais conceitos e fundamentos associados a esses algoritmos que são considerados atuais para uso em compressão de imagem.

Palavras-Chaves

Wavelet, Transformada Wavelet, Processamento Digital de Imagem, Compressão de Imagem.

1. Introdução

As pesquisas envolvendo *wavelets* proporcionaram na última década o desenvolvimento de importantes estudos realizados por pesquisadores das mais diferentes áreas. Talvez tenha sido um dos assuntos científicos que mais interessados tenha reunido, podendo-se citar algumas áreas importantes envolvidas, tais como processamento de sinais, estatística, equações diferenciais, análise numérica, geofísica, física quântica, ciência da computação, entre outras. Essa ampla e crescente demanda de aplicações se deve ao fato de que as propriedades da transformada *wavelets* mostrou para matemáticos, engenheiros, e pesquisadores em geral uma nova e elegante maneira de se ver o mundo (*world-view*).

A análise de Fourier é considerada uma poderosa ferramenta de análise espectral, não obstante existam problemas em que a solução através da transformada de Fourier, torna-se inadequada ou tem uma alta complexidade computacional. Um caso específico é a análise tempo-frequência de sinais. A transformada *wavelet* de uma função (sinal) capta a

informação da localização tempo-frequência do sinal, ao contrário da transformada de Fourier que sacrifica a localização num domínio para garantir o domínio complementar. A propriedade de localização tempo-frequência facilita consideravelmente o estudo do comportamento de sinais, tais como singularidade e suavidade, bem como das características das mudanças locais sem alterações significativas no estado do sinal quando essas características são comparadas com aquelas em outras regiões de frequência ou tempo.

Além disso, no caso discreto, os coeficientes das séries *wavelets* de um sinal com características completamente localizadas no espaço tempo-frequência, correspondem aos coeficientes com uma janela discreta de tempo-frequência. Essa característica inerente à transformada *wavelet* discreta resulta na propriedade de multiresolução que possibilita o estudo do sinal com variação da resolução. Embora a transformada *wavelet* não substitua a transformada de Fourier, existem aplicações onde a transformada *wavelet* constitui-se em uma ferramenta “natural” relativamente superior para se efetuar a análise. Por exemplo, no processamento de sinais não estacionários, como é em geral, o caso das imagens, a transformada *wavelet* não introduz efeitos de blocos. Além disso, a complexidade computacional inferior a da FFT -*Fast Fourier Transform* o que motiva a sua utilização em sistemas práticos. Ainda outra característica da TW é sua alta capacidade de concentrar a energia do sinal em um número reduzido de coeficientes, possibilitando a obtenção de uma representação mais compacta.

O conjunto dessas características fazem dessa transformada uma excelente alternativa aos métodos tradicionais de compressão de imagens.

2. Wavelets

Analogamente à transformada de Fourier (TF), a transformada *wavelets* (TW) decompõe o sinal em conjuntos apropriados de bases de funções. *Wavelets* literalmente significam “*small waves*”, “*ondelletes*” (pequenas ondas). Como o nome sugere, elas são ondas, oscilam e suas curvas têm um decaimento a zero em relação à área algébrica: $\int_{-\infty}^{\infty} \psi(t) dt = 0$.

O termo que sugere pequenez refere-se ao fato de que elas são localizadas no tempo. Isso contrasta com o comportamento das bases de Fourier, pois essas bases são constituídas por senos e cossenos infinitos. Essas funções senoidais e cossenoidais estão perfeitamente localizadas no espaço de frequência, mas não decrescem a zero como uma função do tempo. Por outro lado, as *wavelets* caem a zero quando $t \rightarrow \pm\infty$ e desfrutam da boa propriedade de localização no espaço de tempo.

A construção de uma *wavelet* é realizada a partir da função básica oscilatória de suporte compacto, denominada de *wavelet*-mãe (base), $\psi(t)$, que gera as bases a partir de deslocamentos e dilatações $\psi(at - b)$. Para *wavelets* discretas, os parâmetros através dos quais acontece a dilatação, a , e a translação, b , estão restritos a um conjunto discreto, usualmente, $a = 2^j$, $b = k$ onde j e k são inteiros. Essa estrutura permite que a TW ofereça uma excelente resolução em tempo e frequência e a possibilidade de uma representação hierárquica do conjunto de dados. Essa abordagem é também chamada de análise de multiresolução.

2.1. Transformada Wavelet

As mesmas três possibilidades que existem para a transformada de Fourier (TF), existem para a transformada *wavelet* (TW): a transformada *wavelet* contínua (TWC), expansão em série de *wavelet*, a transformada *wavelet* discreta (TWD). A situação é ligeiramente mais

complexa do que a da TF, pois as funções bases da *wavelet* podem ou não ser ortonormais [1].

Os conjuntos das funções bases dessas *wavelets* podem sustentar a transformada até mesmo quando as funções não forem ortonormais. Isso significa, por exemplo, que uma expansão em série de *wavelet*, pode representar uma função limitada em banda, usando-se uma infinita quantidade de coeficientes. Se essa seqüência de coeficientes é truncada para se obter um comprimento finito, então pode-se reconstruir apenas uma aproximação da função original. Da mesma forma, a TWD pode requerer mais coeficientes do que pontos de amostras obtidas do sinal original a fim de se ter uma reconstrução exata, ou até mesmo uma aproximação aceitável [1].

2.1.1. Transformada *Wavelet* Contínua

A transformada *wavelet* contínua (TWC) da função $f(x)$, foi introduzida por Grossman and Morlet é definida pela seguinte expressão [2, 3]

$$TWC(a, b) = \langle f(x), \psi_{a,b}(x) \rangle = \int_{-\infty}^{\infty} f(x) \psi_{a,b}^*(x) dt. \quad (1)$$

O conjunto das *wavelets*-filhotes, $\psi_{a,b}(x)$ é constituído de versões deslocadas e dilatadas ou comprimidas da *wavelet*-mãe, $\psi(x)$,

$$\psi_{a,b}(x) = \frac{1}{\sqrt{a}} \psi\left(\frac{x-b}{a}\right) \quad (2)$$

Na expressão (2), b é o parâmetro responsável pelo deslocamento da *wavelet* e a corresponde ao escalonamento, parâmetro responsável pela dilatação ou compressão. A constante $a^{-\frac{1}{2}}$ é o termo de normalização da energia da função em relação ao parâmetro a .

O escalonamento utilizado na transformada *wavelet* tem o mesmo significado da escala utilizada nos mapas geográficos, onde as escalas maiores fornecem visões globais enquanto que as menores nos permitem observar os detalhes. Na transformada *wavelet*, escalas

grandes permitem analisar os trechos longos do sinal, enquanto que escalas menores aqueles trechos mais curtos de forma mais detalhada.

2.1.1. Transformada *Wavelet* Discreta

Para se obter a transformada *wavelet* discreta (TWD), os parâmetros de deslocamentos e escalonamento são discretizados. Já a variável independente, isto é, o tempo, permanece contínua.

O conjunto de coeficientes que nos fornece a TWD, correspondem a pontos em uma grade bidimensional no domínio deslocamento-escala. Essa grade é indexada por dois números inteiros, m e n . O inteiro, m está relacionado à escala e o segundo inteiro, n , está relacionado ao deslocamento. O parâmetro de escalonamento a é discretizado de forma exponencial, $a = a_0^m$, enquanto que o parâmetro b é discretizado proporcional a a , $b = nb_0 \cdot a_0^m = k \cdot a_0^m$. As constantes a_0 e b_0 são os comprimentos dos passos discretos de escalonamento e de deslocamento, respectivamente. A TWD de um sinal $f(x)$ é definida como sendo [4, 5]

$$TWD(m, n) = \frac{1}{\sqrt{a_0^m}} \int_{-\infty}^{\infty} f(x) \psi^*(a_0^{-m}x - k) dx \quad (3)$$

Para valores grandes de a , a resolução no tempo é pequena e conseqüentemente, os passos de deslocamentos são grandes. Para valores pequenos de a , a resolução no tempo é grande e os passos de deslocamentos são pequenos. Isso justifica o fato do passo de deslocamento ser proporcional ao escalonamento.




Fig. 1: Grade de amostragem e seu correspondente conjunto de funções, obtidas a partir da discretização dos parâmetros $a = a_0^m$ e $b = n.b_0.a_0^m$. Neste exemplo $a_0 = 2^{1/2}$, $b_0 = 1$.

Como é ilustrado na Fig. 1, cada ponto corresponde-se com uma *wavelet* $\psi_{a,b}(x)$, para diferentes valores de m , correspondem *wavelets* de diferentes larguras. Por exemplo: *Estreitas* (*wavelets* de alta – frequência), são deslocadas através de passos menores, para cobrir o eixo inteiro, enquanto as mais *largas* (*wavelets* de baixa – frequência), são deslocadas através de passos maiores.

Pode-se comparar a análise de um sinal através das *wavelets* com a análise de um material em um microscópio. Para se analisar um material, a primeira providência que se deve tomar é se mover para o local escolhido, o que seria equivalente na análise com *wavelets* a se escolher o valor para k (Eq. 3). Em seguida, deve-se escolher o fator de amplificação, ou seja, a_0^{-m} . Desejando-se ver detalhes muito pequenos do material, a ampliação deve ser grande, o que corresponde a $m < 0$. Como consequência, o valor do produto ka_0^m será pequeno produzindo-se deslocamentos pequenos. Querendo-se visualizar uma área maior,

deve-se escolher uma ampliação menor e, portanto, ka_0^m será maior, levando a deslocamentos maiores.

Para $a_0 = 2, b_0 = 1$, obtem-se a família das *wavelets* diádicas, sendo que esse valor facilita a implementação, já que dilatar um sinal por um fator de 2 corresponde simplesmente a tomar uma amostra sim e outra não do sinal [6]. Assim, quando $a_0 = 2$, diz-se que as frequências são particionadas em oitavas consecutivas.

3. Multiresolução

A análise da informação contida em uma imagem diretamente a partir da intensidade, da escala de cinza dos *pixels*, é um processo muito dificultoso. A representação de multiresolução fornece uma base para a interpretação e análise da informação contida em um sinal. Essa informação é organizada em um conjunto de detalhes com diferentes resoluções. Para um sinal $f(x)$, definido no intervalo $0 < x < x_0$, a sua resolução nos fornece a quantidade de pontos para os quais esse sinal é conhecido. Quando se conhece um sinal com resolução completa, ou o que é o mesmo com um nível de resolução infinita, pode-se dizer que se conhece $f(x)$ para todos os pontos do intervalo. Da mesma forma, pode-se dizer que se conhece um sinal com resolução r_j quando se conhece r_j pontos do intervalo.

Dada uma seqüência crescente de resoluções $(r_j)_{j \in \mathbb{Z}}$, os detalhes com resolução r_j de um sinal são definidos como sendo a diferença de informação entre a sua aproximação com resolução r_j e a sua aproximação com resolução r_{j-1} , mais baixa [7, 8].

Pode-se então escrever para um sinal $f(x)$,

$$f_{2^{j+1}}(x) = f_{2^j}(x) + D_{2^j}f(x). \quad (4)$$

A Eq. 4 representa o sinal $f(x)$ decomposto em dois termos, o primeiro, $f_{2^j}(x)$, corresponde com a aproximação da função no nível de resolução 2^j e o segundo, $D_{2^j}f(x)$, aos sinais de detalhamento para todos os níveis de resolução 2^j , formado a partir da

diferença de informação entre os níveis de resolução 2^j e 2^{j+1} . Sob o ponto de vista de processamento de sinais, pode-se interpretar o primeiro termo como sendo a componente de baixas frequências do sinal e o segundo como sendo a componente de altas frequências.

4. Processamento de Imagens utilizando Transformada Wavelets

O sucesso, no campo da compressão de imagens, utilizando-se a transformada *wavelet*, é principalmente atribuído às estratégias inovadoras para a organização e representação de dados de uma imagem transformada. Tais estratégias exploram de forma implícita ou explícita as propriedades estáticas dos coeficientes transformados em uma pirâmide *wavelet*. A maioria dos codificadores publicados, recentemente na literatura utiliza o algoritmo de decomposição piramidal (diádica). Um exemplo de tal decomposição é mostrado na Fig.2 [9, 10, 11].




Fig. 2: Decomposição *wavelet* em duas escalas para a imagem Lena.

No presente, pode-se selecionar três algoritmos que representam bem os melhores da lista de codificadores *wavelets* para imagens. São eles: “*Embedded Zerotree Wavelet Coder*” (EZW) de Shapiro [11], “*Morphological Representation of Wavelet Data*” (MRWD) de Servetto & Cols [12] e “*Set Partitioning in Hierarchical Trees*” (SPIHT) de Said & Perlman [13]. Ambos, o EZW e o SPIHT exploram a dependência entre subbandas de coeficientes *wavelets* pouco significativos, enquanto o MRWD realiza dentro de uma subbanda um tipo de *clusterização* de coeficientes *wavelets* significativos. Tais

codificadores quando são comparados com o JPEG (“*Joint Photographic Experts Group*”), apresentam um desempenho superior com relação a qualidade visual devido principalmente a eliminação do efeito de blocos. Quanto ao desempenho objetivo, medido a partir da PSNR (“*Peak Signal to Noise Ratio*”) de imagens reconstruídas, tais algoritmos apresentam um aumento consistente da ordem de 1-3 dB sobre os codificadores por transformada de blocos.

Outro algoritmo, que segue a mesma linha do SPIHT e MRWD, é conhecido por “*Significance-Linked Connected Component Analysis*” (SLCCA) de Chais e Cols [14]. O SLCCA é uma extensão do MRWD, visto que além de explorar a *clusterização* de coeficientes significativos (a partir da análise de componentes conectados), também explora a dependência de *clusters* significativos entre subbandas. A dependência entre subbandas é explorada a partir do estabelecimento de um *link* de significância entre um *cluster*-pai (subbanda de baixa frequência) e um *cluster*-filho (subbanda de alta frequência).

Um algoritmo híbrido *wavelet*-fractal, chamado de “*Wavelet-Fractal Coder*” (WFC), foi desenvolvido por Li e Kuo [15]. Esse algoritmo utiliza operadores fractais no domínio *wavelet* para produzir coeficientes de alta resolução a partir dos coeficientes de baixa resolução. O resíduo é então codificado com um “*Layered Zero Coder*” (LCZ) [17], que é um codificador *wavelet* de plano de bit baseado no EZW. Essa estratégia de codificação do resíduo não é aplicada a toda a imagem, mas apenas às partes da mesma que justifiquem o cabeçalho extra. Trata-se de um codificador *wavelet* assistido pela predição fractal.

4.1. Propriedades Estatísticas das Transformadas *Wavelets* de Imagens.

Entre essas propriedades estatísticas, cinco se destacam:

1. Localização espaço-frequência: Um coeficiente wavelet é dito ser espacialmente localizado se contem apenas características de um segmento local de uma imagem de entrada. Devido à própria forma de decomposição de uma imagem em subbandas com quase nenhuma sobreposição, cada subbanda é localizada em frequência com conteúdos aproximadamente independentes. Cada coeficiente wavelet representa informações de uma certa banda de frequências em uma determinada localização espacial.

2. Compactação de energia: Uma imagem natural é tipicamente composta de uma grande porção de regiões homogêneas e regiões de textura. Tal imagem apresenta ainda uma pequena porção de bordas que incluem objetos de fronteiras perceptivelmente importantes. Regiões homogêneas apresentam a menor variação e consistem basicamente de componentes de baixas frequências. Regiões de texturas têm variação moderada e consistem de uma mistura de componentes de baixas e altas frequências. As bordas por sua vez apresentam grande variação e são compostas basicamente de componentes de altas frequências. Por construção, tendo-se por base o algoritmo piramidal, cada vez que uma subbanda passa-baixas em uma resolução fina é decomposta em quatro subbandas numa resolução mais grosseira, um processo de amostragem crítico permite gerar uma nova subbanda com apenas um quarto do tamanho da subbanda passa-baixas original. Repetindo-se esse processo de decomposição em uma imagem, isso resultará em uma compactação efetiva de energia em poucos coeficientes wavelets. Isso é devido a que grande parte da energia contida em regiões homogêneas e de textura, tende naturalmente a se concentrar numa subbanda passa-baixas.

3. Clusterização de coeficientes significativos em uma subbanda: Um coeficiente wavelet c é dito ser significativo com relação a um determinado limiar T se $|c| \geq T$; caso

contrário tal coeficiente é considerado insignificante. Um coeficiente insignificante também é conhecido como coeficiente zero. Devido à ausência de componentes de altas frequências em regiões homogêneas e à presença de componentes de altas frequências em regiões de textura e em torno das bordas, coeficientes significantes em subbandas passa-altas indicam usualmente a ocorrência de bordas e texturas com alta energia. Isso significa que tais coeficientes indicam uma proeminente descontinuidade ou uma proeminente mudança, um fenômeno que tende a ser clusterizado. A clusterização dentro da imagem Lena é mostrada na Fig. 3, sendo que o mapa de sementes para geração de cada um dos *clusters* é mostrado na Fig. 4.




Fig. 3: Clusterização de coeficientes significantes.




Fig. 4: Mapa de Sementes para a geração dos *clusters* significantes. A forma dos *clusters* é irregular e depende da semente que a origina.

4. Similaridade entre subbandas em diferentes escalas: Dado um coeficiente wavelet, como mostrado na Fig. 5, todos os coeficientes numa escala mais fina de orientação similar que correspondem a mesma orientação espacial são chamados seus descendentes, sendo por essa razão, o dado coeficiente chamado de ancestral. Especificamente, um coeficiente em uma escala grosseira é chamado de pai e todos os quatros coeficientes que correspondem à mesma localização espacial na próxima escala mais fina, são chamados de filhos. Embora a correlação entre os valores dos coeficientes pais e filhos seja extremamente pequena, há uma dependência adicional entre as magnitudes de ambos. Experimentos mostram que a correlação entre a magnitude quadrática de um filho e a magnitude quadrática do pai tende a estar entre 0,2 e 0,6 com uma forte concentração em torno de 0,35. Essa dependência em magnitude quadrática caracteriza a similaridade entre as subbandas [11, 17].




Fig. 5: Similaridade entre subbandas cruzadas de mesma orientação. A similaridade entre os coeficientes insignificantes (zeros) pode ser compactamente representada numa árvore de zeros (*zerotree*).

5. Decaimento da magnitude de coeficientes wavelets entre subbandas à medida que se refina a escala de resolução: Embora pareça difícil caracterizar e utilizar por completo essa similaridade de magnitude entre descendentes, uma conjectura razoável baseada na experiência com imagens naturais é que a magnitude do filho é menor do que a magnitude

do pai. Assumindo um campo de Markov aleatório como modelo da imagem, pode-se comprovar que estatisticamente a magnitude dos coeficientes wavelets decai de pai para filho. Mais precisamente, se a magnitude do coeficiente for medida por sua variância, pode-se mostrar que um pai tem uma variância maior do que a do filho.

4.2. Estratégias para a Organização e Representação de Dados

Existem duas propostas diferentes para se organizar e representar coeficientes *wavelets* na literatura [11, 12, 13, 14].

Primeira Abordagem: O EZW e o SPIHT usam uma estrutura regular em árvore ou uma estrutura de conjuntos particionados em árvore para aproximar campos insignificantes ao longo de subbandas descendentes. Esses algoritmos exploram as propriedades estatísticas 1, 2, 4, e 5 de modo que se for encontrado um coeficiente pai zero, a probabilidade de seus descendentes serem zero é muito alta, principalmente a partir dos netos.

Segunda Abordagem: Adotada pelo MRWD, utiliza as propriedades estatísticas 1, 2, 3, e 4 para encontrar *clusters* irregulares de campos significativos dentro de subbandas.

Diferentemente do EZW e do SPIHT, o MRWD atua diretamente nos coeficientes significativos, formando *clusters* com formas irregulares de coeficientes significativos dentro das subbandas como é mostrado na Fig. 4. Tal como o MRWD, o SLCCA explora a propriedade que os coeficientes *wavelets* significativos têm de tenderem a se agrupar em *clusters* irregulares (na forma) dentro de uma subbanda.

4.3. Avaliação do Desempenho dos Algoritmos.

Os algoritmos EZW, SPIHT, SLCCA, MRWD e WFC são comparados utilizando-se as imagens Lena (Fig.6), Bárbara (Fig.7), e Baboon (Fig.8), todas elas em tons de cinza com

dimensão 512 x 512. Todas as imagens foram decompostas a partir de uma transformada *wavelet* diádica (pirâmide de subbandas), utilizando-se filtros *spline* biortogonais 9/7. Não foi utilizada alocação de bits ótima. Primeiro, os coeficientes *wavelets* foram quantizados com o mesmo quantizador escalar uniforme. Os resultados foram então codificados em planos de bits de acordo com o método determinado pelo algoritmo em questão. O desempenho desses algoritmos é medido da forma usual a partir de curvas de taxas de distorção, onde a taxa é medida em bits por *pixel* e a distorção PSNR (*Peak Signal to Noise Ratio*). A PSNR é definida na Eq. 5, e o RMSE é a raiz quadrada do erro quadrático médio entre a imagem reconstruída e a imagem original [16].

$$PSNR(db) = 20 \log_{10} \frac{255}{RMSE}. \quad (5)$$



Fig 6. Imagem Lena



Fig 7. Imagem Bárbara




Fig 8. Imagem Baboon

Na Fig. 9, compara-se os desempenhos dos algoritmos EZW, SPIHT, MRWD, SLCCA e WFC a partir de suas curvas de taxas de distorção obtidas para a imagem Lena. Nessa mesma figura, apresenta-se como referência, o desempenho do JPEG para essa mesma imagem. Observa-se a partir desse resultado que os algoritmos *wavelets* para compressão de imagens, representados pelos algoritmos SPIHT, MRWD, SLCCA e WFC, têm um desempenho superior ao JPEG. Isso se torna mais evidente quando os resultados são comparados, tendo-se em vista que tais algoritmos não apresentam artefatos devido ao efeito de blocos tão comuns no JPEG. Entre os demais algoritmos, o EZW foi o que apresentou pior desempenho. Isso era esperado porque o EZW é um referencial, devido a que foi o primeiro algoritmo que levou as *wavelets* ao topo do reconhecimento dentro dos compressores de imagem tanto em eficiência quanto em simplicidade (computacional). De fato, muitos algoritmos, entre eles o LZC de Taubman [17], foram desenvolvidos a partir do EZW.

Pelos resultados da Fig.9, o MRWD e SPIHT tiveram desempenhos semelhantes a partir de conceitos diferentes. O MRWD explora as propriedades que os coeficientes significativos dentro de uma subbanda de detalhes apresentam, ou seja, tendem a se *clusterizar*, e o SPIHT explora a propriedade de dependência entre as subbandas de coeficientes insignificantes (zeros). O SLCCA obteve um desempenho superior ao MRWD e SPIHT. O WFC obteve desempenho médio comparável ao do SLCCA para a imagem Lena.




Fig.9: Desempenho do EZW, SPIHT, MRWD, SLCCA, WFC e JPEG para imagem Lena

Na Fig. 10, o desempenho dos algoritmos foi semelhante ao obtido para a imagem Lena. A diferença está no desempenho do WFC que para essa imagem foi ligeiramente superior ao SLCCA. Uma explicação para esse fenômeno está nas diferenças entre as imagens Lena e Barbara. A imagem Barbara apresenta um número bem maior de regiões de textura do que a imagem Lena. Tanto o SLCCA quanto o WFC apresentam um bom desempenho em regiões de textura. Porém Lim [18] demonstrou que são exatamente as regiões de textura e de bordas as de predição fractal mais eficiente. Por esse motivo, o WFC teve um desempenho superior ao SLCCA para todas as taxas de bits analisadas para a imagem Barbara. Entretanto o desempenho mostrado na Fig.11 para a imagem Baboon mostrou uma inversão de desempenho. Nesse caso, o WFC obteve o pior resultado entre os codificadores avaliados mesmo sendo a imagem Baboon uma imagem com alto conteúdo de bordas. A explicação nesse caso é que o WFC utiliza a predição fractal em conjunto com o LZC [17] e tanto o LZC quanto o EZW não têm um desempenho tão elevado em imagens muito ricas em detalhes. Nesse caso, o codificador *wavelet* utilizado, diminuiu o desempenho do WFC.

Sugere-se então para solucionar esse problema a implementação da predição fractal com o SLCCA ou MRWD.

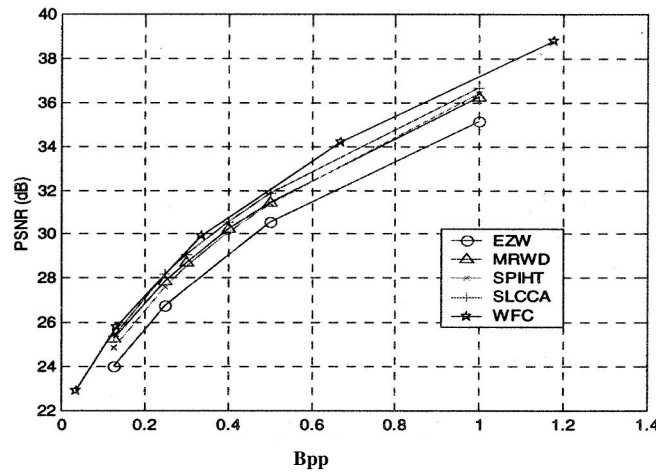


Fig.10: Desempenho do EZW, SPIHT, MRWD, SLCCA, e WFC para a imagem Bárbara .

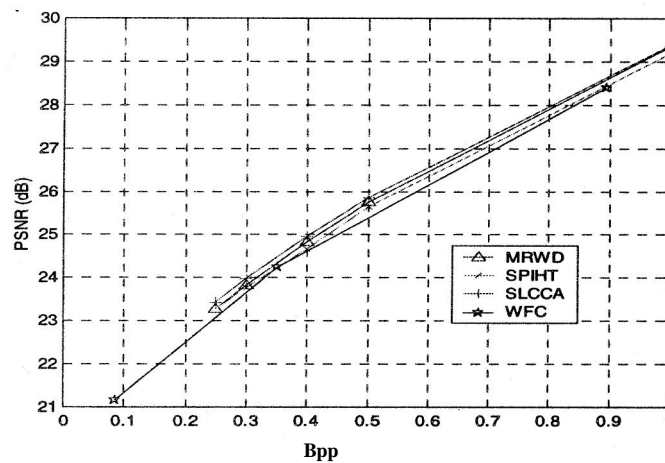


Fig.11: Desempenho do MRWD, SPIHT, SLCCA e WFC para a imagem Baboon.

5. Conclusões

Neste trabalho foi apresentado um estudo das potencialidades da transformada wavelet. Mostrou-se que o sucesso da transformada wavelet no processamento e compressão de imagens é baseado nas estratégias inovadoras para representação e organização dos dados da imagem transformada e que essas estratégias exploram as propriedades estatísticas dos

coeficientes transformados na pirâmide wavelets. Comparou-se também os algoritmos considerados estados da arte em compressão de imagens.

Referencias Bibliográfica

- [1] Kenneth R. C. Digital Image Processing. USA, 1998. 388 p.
- [2] Grossman A. , Morlet J. Decomposition of Hardy Funtion into Square Integrable Wavelet of Constante Shape. SIAM J. Math., USA, v.15, pp. 723-736, 1984.
- [3] Chui C. K. An Introdution to Wavelet. Academic Press, San Diego, 1992.
- [4] Chui C. K. An Introdution to Wavelets. Academic Press Inc. , San Diego, 1992.
- [5] Vetterli M. , Kovacevic J. Wavelet and Subbanda Coding. New Jersy. Prentice - Hall, 1995. 488p.
- [6] Oppenheim A.V. , Schafer R.W. Digital Signal Processing. Englewood Cliffs Prentice Hall Inc., 1975.
- [7] Mallat S. A Wavelet Tour of Signal Processing. Academic Press, San Diego, 1997.
- [8] Mallat Stephane G. A Theory for Multiresolution Signal Descomposition: the Wavelet Representation. IEEE Transactions on Pattern Analysis and Machine Intelligence, USA, v.11, n.7, Julho 1989
- [9] Antonini M., Barland M. , Matheiu P. Duabechies I. Image Coding Using Wavelet Transform. IEEE Transactions on Image Processing, USA, v. 1 n.2, p. 205-220 ,Abril 1992.
- [10] Brislawn M. C. , Bradly J. N. , Hopper T.The FBI Compression Standard for Digitized Fingerprint Images. Proceeding of The SPIE Conference, pp.2847, Applications of Digital Image Processing XIX 1996.
- [11] Shapiro J. M.Embedded Image Coding Using Zerotrees of Wavelets coefficients. IEEE Trans. Signal Processing, USA, v.41, n. 12 p.3445-3462, Dezembro, 1993.
- [12] Servetto S. , Ramchandran K. , Orchard M. T. .Wavelet based Image Coding via Morfological Predition of Significance. IEEE Trans. Image Processing, USA, v.41, n. 12 p.3445-3462, Dezembro, 1998.
- [13] Said A. , Pearlman W. A.A New Fast and Efficient Image Codec based on set Partitioning in Hierarchical Trees. IEEE Trans. Circuit Syst. Video Technol., USA, v.6, n3 p.243-250, Junho, 1996.

- [14] Bing-Bing Ch., Vass J., Zhuang X. Significance-Linked Connect Component analysis for Wavelets Image Coding. IEEE Trans. Image Processing, USA, v.8, n. 6 Junho, 1999.
- [15] Li J. Kuo J. C. Image Compression with a Hibrid Wavelet - Fracta Coder. IEEE Trans. Image Processing, USA, v.8, n. 6, Junho, 1999.
- [16] Sablón Becerra.V., Iano Y. Processamento e Compressão do Espaço de Sinal de Vídeo aplicado às Imagens de Televisão Convencional e HDTV, utilizando a Transformada de Wavelet. DECOM, FEEC, UNICAMP. Relatório No 2 –FAPESP. Faculdade de Engenharia Elétrica, Universidade Estadual de Campinas.Mar,2000.
- [17] Taubman D. , Zakhor A. Multirate 3-D Subbanda Coding of Video. IEEE Trans. Image Processing, Special issue on image Sequence copressionUSA, v.3 n.5, p572-588, Setembro, 1994.
- [18] Lim J.S. Two Dimensional Signal and Image Processing. Pretice Hall,Englewood Cliffs, NJ 1990.pp.695.